Diploma Santé la prépa médecine

Révisions :

UNIVERSITÉ PARIS EST CRETEIL
2025 - 2026

Bio-Informatique

Fiche de cours n°1

Introduction à la bio-informatique

PLAN

I. Génome

II. L'ère de la génomique

III. Dogme central de la biologie moléculaire

IV. Historique des technologies d'analyse génomique

V. Séquençage du génome humain

Légendes

Notion nouvelle cette année

Notion hors programme

Notion déjà tombée au concours

Astuces et méthodes

I. Génome	**Définitions**

	• Ensemble de **l'information génétique** d'un organisme contenu dans **chacune de ses cellules** sous la forme de **chromosomes**
	• Le support matériel du génome est l'ADN
	• Tout l'ADN sur tous les chromosomes, comprend :
	  ○ Les gènes
	  ○ Les séquences intergéniques et les séquences répétées
	  ▪ Partie non codante de l'ADN
	  ▪ Représente 98% du génome
	• Les eucaryotes peuvent avoir **2 ou 3 génomes**
	  ○ Génome **nucléaire** dans le noyau
	  ○ Génome **mitochondrial** dans les mitochondries
	  ○ Génome **plasmidique**
	• Sans précision, le terme "génome" fait généralement référence au **génome nucléaire**
	 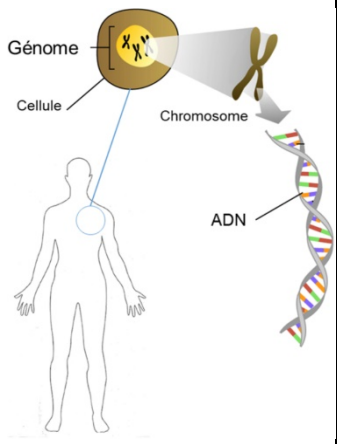

II. L'ère de la génomique	**Description**

	• 1979 : Victor Mckusick, généticien, introduit le terme **génomique** comme discipline consacrée à l'étude du génome
	• **Adénine (A), Guanine (G), Thymine (T) et Cytosine (C)**
	  ○ Bases formant des paires chimiques **A-T** et **C-G**
	  ○ Organisation en double hélice d'ADN
	  ○ Détermine notre **code génétique unique**
	  ○ Fournit les instructions pour la production de molécules dans notre organisme
	 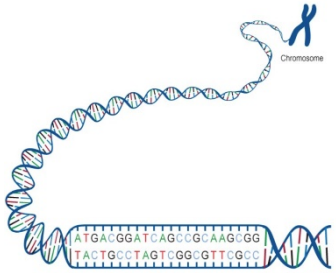
	• L'ADN reproduit de nouvelles copies de lui-même pendant la division cellulaire
	  ○ Au cours de ce processus, des **erreurs peuvent se produire**
	  ○ La machinerie de réparation cellulaire peut, ou non, corriger les erreurs
	  ○ Les erreurs peuvent être transmises sous forme de **mutations**
	  ○ Assimilable à un problème de manipulation de **chaînes de caractères**

III. Dogme central de la biologie moléculaire	**Explication**

- 1958 : 1ère proposition de **dogme central** par **Francis Crick**
  - En biologie moléculaire, le flux d'informations génétiques est toujours à sens unique
  - Il part des acides nucléiques
  - Va aboutir aux protéines
- L'ADN peut se **répliquer** au cours des divisions cellulaires
  - Les gènes qu'il contient peuvent être transcrit en molécule d'ARN qui ont la particularité d'avoir des bases **d'Uracile** au lieux des **thymines** sur l'ADN
  - L'ARN passe du noyau au cytoplasme
    - Traduction en protéines
    - Composées de 20 acides aminés possible
  - Plus de 20 000 gènes composent le génome humain
- Dogme central : l'**ADN** dirige sa propre **réplication** en ADN identique, ainsi que sa **transcription** en **ARN**, pouvant ou non être **traduit** en **protéines**

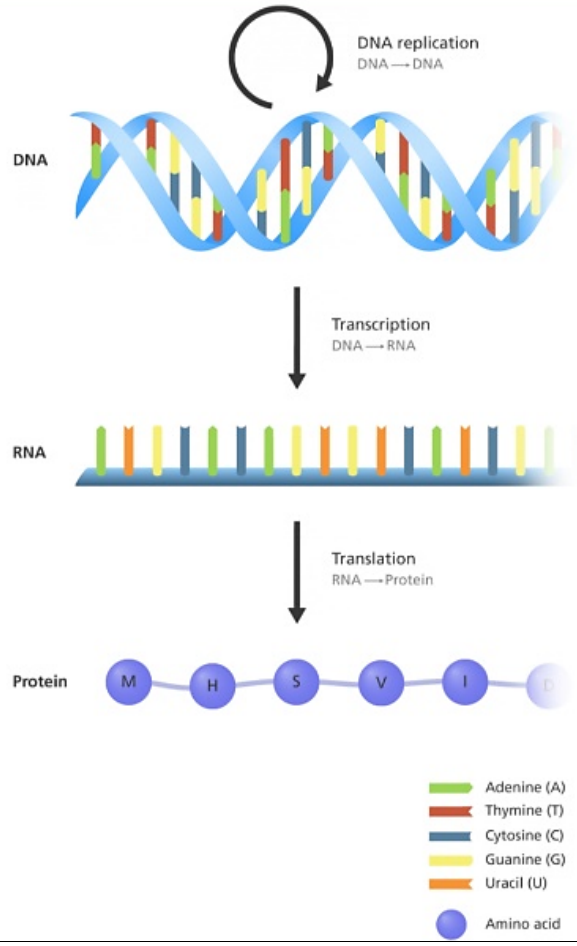

IV. Historique des technologies d'analyse génomique	**Description**

	• Détermination de la séquence nucléotidique :
	  ○ Etape fondamentale pour comprendre les processus biologiques et les altérations de la séquence
	  ▪ Peuvent être responsables de l'apparition de plusieurs maladies
	 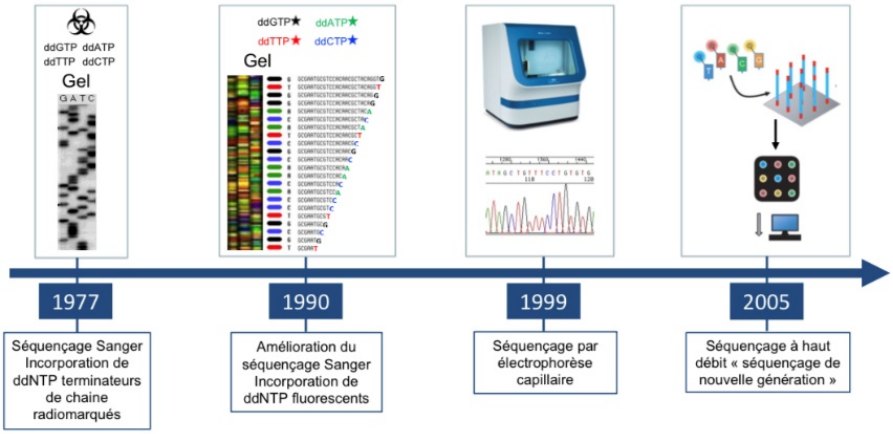
	
	• Séquençage : technique essentielle permettant de déterminer la nature et l'ordre des bases
	• 1977 : **Méthode de Sanger** : Synthèse de brins complémentaires à celui dont on veut obtenir la séquence
	  ○ Interrompus par des didésoxyribonucléotides terminateurs de chaine
	• 1990 : Incorporation des **ddNTP marqués**
	  ○ Permet la construction de plusieurs fragments d'ADN complémentaires à la séquence
	  ○ Sont **séparés sur le gel** du **plus petit au plus grand**
	• 1999 : **Automatisation** de la méthode de Sanger
	  ○ C'est le séquençage par **électrophorèse capillaire**
	• 2005 : Vraie révolution des méthodes de séquençage :
	  ○ Séquençages de nouvelle génération (NGS)
	  ○ Rupture avec le passé

V. Séquençage du génome humain	**Généralités**

- Février 2001 : Publications des premiers assemblages
- Avril 2003 : Génome humain déclaré comme entièrement séquencé
  - Étude collaborative
  - Séquençage du premier génome entier au bout d'une dizaine d'années
  - Aujourd'hui on peut avoir le même résultat en quelques jours

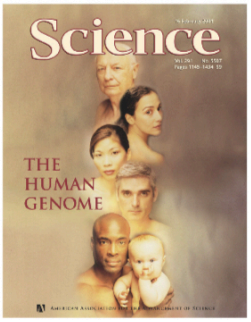

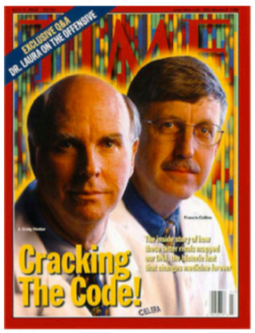

- Démocratisation des nouvelles méthodes et accessibles à tout le monde
  - Résultats de façon beaucoup plus rapide et moins coûteuse

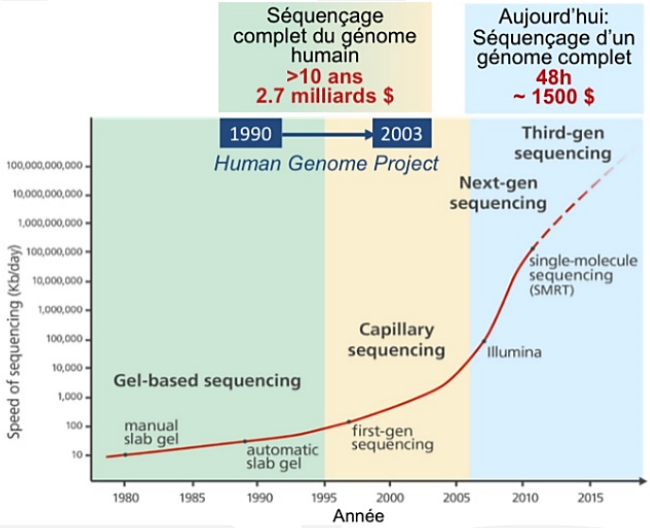

Plus rapide, Moins cher !

V. Séquençage du génome humain	**Les technologies du NGS**

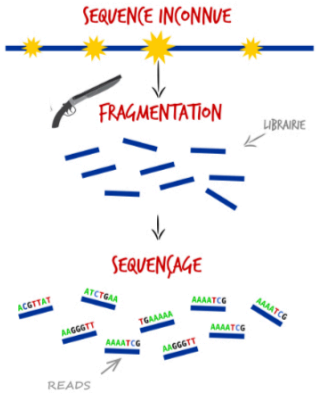

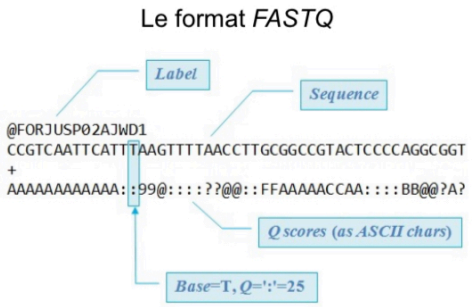

- Séquençage de nouvelle génération : fragmenter la séquence d'ADN en plusieurs fragments
  - Ces fragments font partis de la **« librairie »**
  - La librairie peut être amplifiée et séquencée avec ces méthodes de nouvelle génération
- Les séquences de ces fragments sont appelées des **« reads »**
  - À la fin du séquençage les séquences reads sont regardées dans des fichiers au format FASTQ
    - Ces fichiers sont très importants
    - Format de référence pour représenter les résultats de toutes les méthodes de séquençage de nouvelle génération
  - Toutes les plateformes de NGS sont capables de fournir un fichier FASTQ
  - C'est un fichier format texte où l'information de la séquence est contenue en 4 lignes :
    - 1ère ligne : commence par le **symbole @**
      - C'est l'identifiant alpha numérique de la read
      - C'est un label, identifiant unique pour chaque read
    - 2ème ligne : contient la **séquence de read**
    - 3ème ligne : commence par le **symbole +**
      - Veut dire que la séquence a aussi un score de qualité
      - À chaque base on peut donner un score de qualité pour savoir si la base obtenue à cette position donnée est la bonne ou pas.
    - 4ème ligne : contient **le score**
      - Les scores ne sont pas numériques pour des raisons d'espace
      - Ils sont codés par les caractères ASCII
      - Ce sont des Q scores pour chaque base
      - Ils vont de 1 à 40

V. Séquençage du génome humain	**Les technologies du NGS (Suite)**

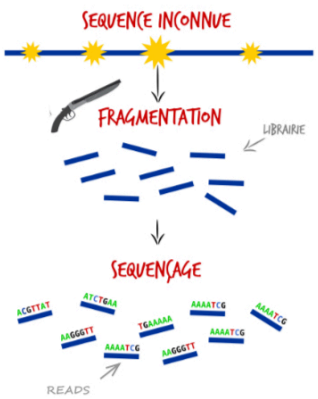

- **Assemblage de novo** :

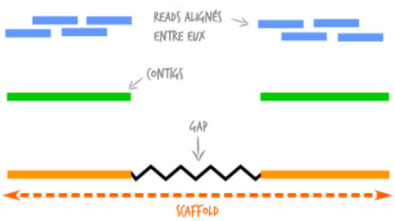

- **Alignement avec référence**:

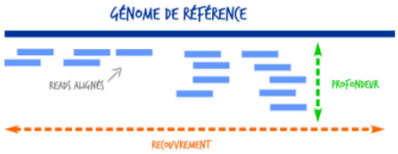

- Pour une séquence du génome complet il faut reconstruire à partir de ces fragments, un puzzle réalisant un alignement
  - Intérêt de l'informatique et au mieux de la bio-informatique dans la reconstruction des séquences obtenues par NGS
  - Cet alignement peut se faire :
    - Par un **assemblage de novo :** on essaie de résoudre ce puzzle sans avoir un modèle de référence
  - Avec la bio-informatique on essaie de reconstruire la séquence grâce à des fragments chevauchants
  - Lorsqu'on arrive à reconstruire une séquence plus grande en utilisant plusieurs reads chevauchant on appelle cela « contigs »
  - Ensuite on construit une séquence encore plus grande en assemblant plusieurs contigs on obtient la séquence d'un scaffold
    - Par un **alignement avec référence :** on résout toujours un puzzle mais cette fois on s'aide d'un modèle c'est à dire d'un génome de référence
  - On essaie d'utiliser nos fragments et de les aligner avec le génome de référence
  - Intérêt dans l'étude des maladies :
    - On peut voir si dans l'échantillon avec un segment C il y a des mutations sur une position donnée qu'il n'y a pas dans un génome de référence
  - Les deux termes importants pour cette méthode sont : **l'alignement** et la **profondeur**
  - La profondeur est le nombre moyen de reads qui sont superposés
  - Le recouvrement ou la couverture c'est l'étalement des reads sur la zone d'intérêt
- Pour les deux méthodes la taille des fragments est très importante
  - Plus les pièces du puzzle sont petites plus il est difficile de les reconstruire
  - Il y a alors plusieurs méthodes de séquençage de nouvelle génération

V. Séquençage du génome humain	**Les technologies du NGS (Suite)**

	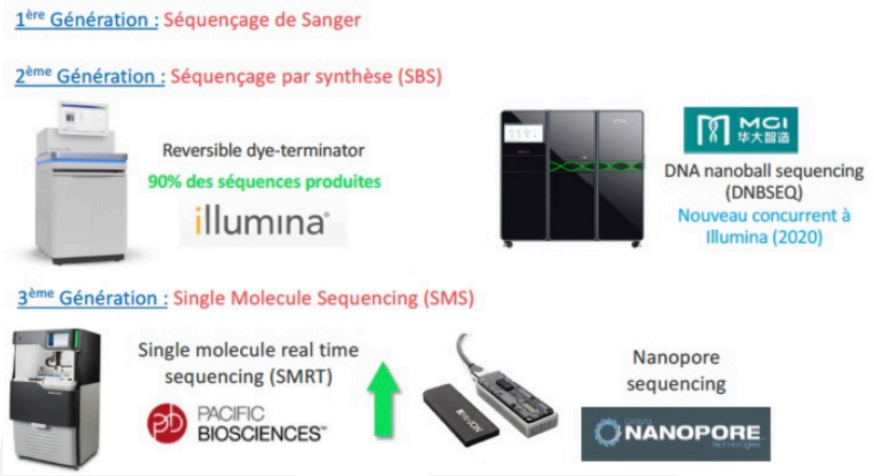
	• Les méthodes de 2ème et 3ème générations se distinguent par la taille des reads
	  ○ 2ème génération : méthode de « short reads » - « reads courts »
	  ○ 3ème génération : méthode qui permet une reconstruction plus rapide car de « longs reads » - les tailles de fragments sont plus grandes

V. Séquençage du génome humain	**Généralités**

Les techniques de séquençage de nouvelle génération	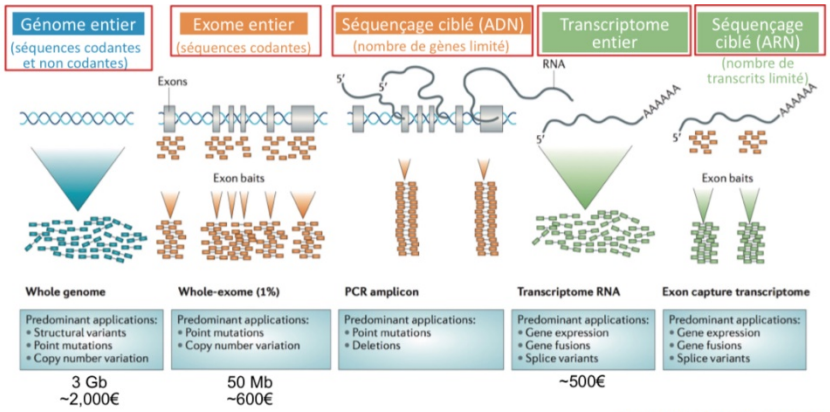
	Simon et al., Nat Rev Drug Disc 2013
	• Techniques de 2ème et 3ème générations : séquençage du génome et de l'exome entier
	  ○ Avec les exons (partie codante du gène) on peut séquencer tous les exons de tous les gènes qui font partie du génome
	  ○ Correspond à 50 millions de bases
	  ○ Séquençage du génome entier correspond aux :
	  ▪ Parties codantes (exons)
	  ▪ Parties non codantes (introns)
	  ▪ = env. 3 milliards de bases
	  ○ 98% du génome est donc non codante
	• On peut aussi séquencer des parties spécifiques de l'ADN
	  ○ On parle de **séquençage ciblé**
	• Enfin on peut séquencer l'ARN :
	  ○ soit tout l'ARN : transcriptome,
	  ○ soit de l'ARN ciblé

Analyse génomique	• Passage de l'analyse des séquences à l'analyse des génomes se caractérise par :
	  ○ Un **changement d'échelle:**
	  ▪ Quelques séquences → milliers de séquences
	  ○ Un **changement de vision:**
	  ▪ Vision statique → vision dynamique (plusieurs gènes à la fois, leurs interactions)
	• L'accumulation sans précédent de données nous conduit vers un :
	  ○ **Défi quantitatif** pour le stockage de ces données.
	  ○ **Défi qualitatif** pour leur analyse
	  ▪ Accumulation des données plus vite que notre capacité à les analyser
	  ○ Utilisation de de nouvelles ressources, notamment la bio informatique

V. Séquençage du génome humain	**Bioinformatique**

Définition	• Utilisation de l'informatique pour stocker et analyser les données biologiques ou médicale
	  ○ Permet de résoudre des problèmes d'ordre de la biologie et de la médecine
	• Interdiscipline à la frontière de la biologie, de l'informatique et des mathématiques
	• Discipline de l'analyse « in silico » de l'information biologique renfermée dans la séquence nucléotidique et protéiques
	  ○ Tous les projets biologiques comportent une étape d'analyse bioinformatique des données
	  ○ Un biologiste passe 1 à 30% de son temps à utiliser des outils bioinformatique
	  ○ Importance majeure de cette nouvelle discipline dans la biologie et la médecine