Diploma Santé la prépa médecine

Révisions :

UNIVERSITÉ PARIS EST CRETEIL
2025 - 2026

Bio-informatique

Fiche de cours n°3

La comparaison de séquences

PLAN

I. Comparaison de séquences

II. Alignement de séquences

III. Matrice de substitution

IV. Programmation dynamique

V. Recherche globale ou locale

VI. BLAST (Basic Local Alignment Search Tool)

Légendes

Notion nouvelle cette année

Notion hors programme

Notion déjà tombée au concours

Astuces et méthodes

I. Comparaison de séquences

Description

AGATTCCAT — *séquence ADN*

AGAUUCCAU — *séquence ARN*

IPLMTRWDQEQES — *séquence d'acides aminés*

- **3 types** de séquence biologique : séquence d'ADN, d'ARN ou d'acides aminés
  - ADN et ARN : formés par la combinaison de **4 bases possibles**
  - Séquences d'acides aminés ou de protéines : formées par la combinaison de **20 acides aminés possibles**
- Possibilité **d'étudier les séquences** de nucléotides ou d'acides aminés
  - Fournissent des informations importantes sur leur **fonction**
- Plus deux **séquences sont similaires** (composées dans le même ordre et des mêmes éléments), plus il est probable que leur **fonction soit similaire**

II. Alignement de séquences

Comparaison de séquences de nucléotides ou d'acides aminés

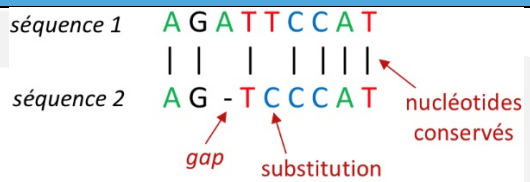

- Méthode la plus utilisée : **les aligner**
  - Représenter les **2 séquences** l'une sur l'autre en **empilant** leurs résidus
  - Lorsque 2 séquences ont des éléments égaux = nucléotides conservés
    - 2 séquences de périodes évolutives différentes donc conservés sur l'évolution
  - **Substitution** possible : une base devient une autre base durant l'évolution
    - Thymine devient cytosine ou cytosine devient thymine
  - Gap possible en 3ème position : un trou ou une base n'est alignée avec aucune autre base, dû à 2 mécanismes possibles pendant l'évolution :
    - Soit la séquence a gagné par ex. une Adénine = **insertion**
    - Soit la séquence a perdu cette Adénine = **délétion**
- **Pourcentage d'identité (%Id) : nombre d'identité entre 2 séquences après alignement des séquences, rapporté à la longueur de l'alignement**
  - Ex. : on a 9 bases possibles (alignement) et 7 sont conservés (nombre d'identité) :
    - Id% = (7/9) * 100 = 77%

- Ex. : ici on constate que dans les 3 premières positions de la 1ère séquence il y a 3 gap
  - 4 gap également dans les dernières positions de la 2ème séquence
  - Certains éléments sont conservés dans la partie initiale et dans la partie finale (à peu près 15 résidus conservés)
  - Dans la partie centrale il y a 11 substitutions

II. Alignement de séquences	**Comparaison de séquences de nucléotides ou d'acides aminés**

- En réalité les 2 séquences sont identiques mais avec un **léger décalage de position**
  - On peut alors imaginer que l'on insère des gap à certaines positions
  - On a perdu les 11 anciennes substitutions
  - On a gagné d'autres résidus conservés
  - Ce type d'alignement et donc mieux car on a plus de résidus conservés
  - On donne un score pour savoir quel est l'alignement le plus correct
  - Il est mis en place par un algorithme qu'on appelle « d'alignement »
- Scores d'alignement possibles:
  - **1 si les deux résidus alignés sont égaux sinon 0**

```
- - - I P L M T R W D Q E Q E S D F G H K L P I Y T R E W C T R G   3+4 gap
        I I I I I I I I I                       I I I I I I         15 conservés
C H K I P L M T R W D Q Q E S D F G H K L P V I Y T R E W - - - -   11 substitutions
0 0 0 1 1 1 1 1 1 1 1 1 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 0 0 0 0   Score= 15

- - - I P L M T R W D Q E Q E S D F G H K L P - I Y T R E W C T R G   4+5gap
        I I I I I I I I I   I I I I I I I I I I   I I I I I I         25 conservés
C H K I P L M T R W D Q - Q E S D F G H K L P V I Y T R E W - - - -   ~~11 substitutions~~
0 0 0 1 1 1 1 1 1 1 1 1 0 1 1 1 1 1 1 1 1 1 1 0 1 1 1 1 1 1 0 0 0 0   Score= 25
```

  - **-1 si gap ou substitution sinon 0**
- La première des 2 mesures peut être considérée comme une **mesure de similarité**
  - La seconde peut être considérée comme une **mesure de la divergence**
- **L'algorithme d'alignement doit trouver l'alignement qui produit le score de similarité maximum ou le score qui minimise la divergence**

```
- - - I P L M T R W D Q E Q E S D F G H K L P I Y T R E W C T R G   3+4 gap
        I I I I I I I I I                       I I I I I I         15 conservés
C H K I P L M T R W D Q Q E S D F G H K L P V I Y T R E W - - - -   11 substitutions
-1 -1 -1 0 0 0 0 0 0 0 0 0 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 0 0 0 0 0 0 0 -1 -1 -1 -1   Score= -18

- - - I P L M T R W D Q E Q E S D F G H K L P - I Y T R E W C T R G   4+5gap
        I I I I I I I I I   I I I I I I I I I I   I I I I I I         25 conservés
C H K I P L M T R W D Q - Q E S D F G H K L P V I Y T R E W - - - -   ~~11 substitutions~~
-1 -1 -1 0 0 0 0 0 0 0 0 0 -1 0 0 0 0 0 0 0 0 0 0 -1 0 0 0 0 0 0 0 -1 -1 -1 -1   Score= -9
```

III. Matrice de substitution	**Explication**

- Les acides aminés ont des propriétés physico-chimiques plus ou moins différentes

A	Alanine	Ala
C	Cysteine	Cys
D	Aspartic Acid	Asp
E	Glutamic Acid	Glu
F	Phenylalanine	Phe
G	Glycine	Gly
H	Histidine	His
I	Isoleucine	Ile
K	Lysine	Lys
L	Leucine	Leu
M	Methionine	Met
N	Asparagine	Asn
O	Pyrrolysine	Pyl
P	Proline	Pro
Q	Glutamine	Gln
R	Arginine	Arg
S	Serine	Ser
T	Threonine	Thr
U	Sélénocystéine	Sec
V	Valine	Val
W	Tryptophane	Trp
Y	Tyrosine	Tyr
B		
Z		
X	Inconnu	

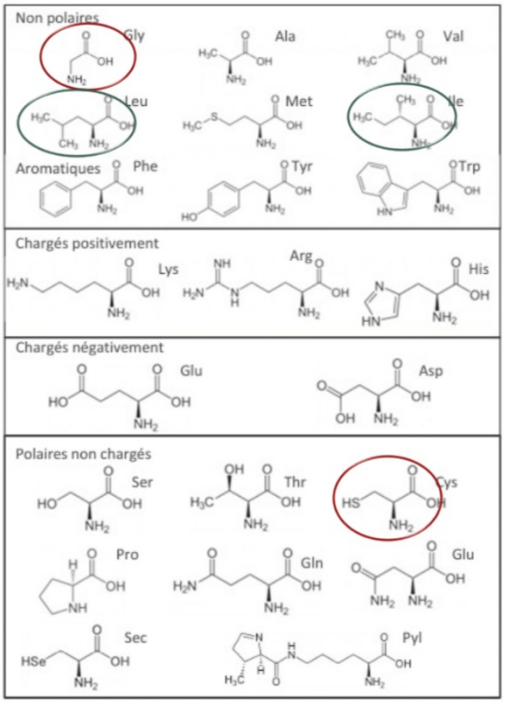

- **Gly → Cys** effet délétère probable
  - Car deux acides aminés très différents
- **Ile → Leu** conserve la structure/fonction
- **Ile → Leu** meilleur score d'alignement
  - Scores donné en fonction du type de changement
  - **Plus le score est élevé, plus la similarité est élevée entre les 2 acides aminés**
    - Plus ce type de mutation a un sens d'un point de vue évolutif
- Matrices de similarité ou **matrices de substitution** :
  - Donne un score de similarité ou de ressemblance entre 2 acides aminés
- 1ère matrice de substitution (M. Dayhoff) :
  - Basée sur le fait que les mutations accumulées au cours de l'évolution n'ont pas altéré la fonction des protéines
  - = Mutations ponctuelles acceptées (ou PAM, Point Accepted Mutation)

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V	B	Z	X	*
A	2	-2	0	0	-2	0	0	1	-1	-1	-2	-1	-1	-3	1	1	1	-6	-3	0	0	0	0	-8
R	-2	6	0	-1	-4	1	-1	-3	2	-2	-3	3	0	-4	0	0	-1	2	-4	-2	-1	0	-1	-8
N	0	0	2	2	-4	1	1	0	2	-2	-3	1	-2	-3	0	1	0	-4	-2	-2	2	1	0	-8
D	0	-1	2	4	-5	2	3	1	1	-2	-4	0	-3	-6	-1	0	0	-7	-4	-2	3	3	-1	-8
C	-2	-4	-4	-5	12	-5	-5	-3	-3	-2	-6	-5	-5	-4	-3	0	-2	-8	0	-2	-4	-5	-3	-8
Q	0	1	1	2	-5	4	2	-1	3	-2	-2	1	-1	-5	0	-1	-1	-5	-4	-2	1	3	-1	-8
E	0	-1	1	3	-5	2	4	0	1	-2	-3	0	-2	-5	-1	0	0	-7	-4	-2	3	3	-1	-8
G	1	-3	0	1	-3	-1	0	5	-2	-3	-4	-2	-3	-5	0	1	0	-7	-5	-1	0	0	-1	-8
H	-1	2	2	1	-3	3	1	-2	6	-2	-2	0	-2	-2	0	-1	-1	-3	0	-2	1	2	-1	-8
I	-1	-2	-2	-2	-2	-2	-3	-2	5	2	-2	2	1	-2	-1	0	-5	-1	4	-2	-2	-1	-1	-8
L	-2	-3	-3	-4	-6	-2	-3	-4	-2	2	6	-3	4	2	-3	-3	-2	-2	-1	2	-3	-3	-1	-8
K	-1	3	1	0	-5	1	0	-2	0	-2	-3	5	0	-5	-1	0	0	-3	-4	-2	1	0	-1	-8
M	-1	0	-2	-3	-5	-1	-2	-3	-2	2	4	0	6	0	-2	-2	-1	-4	-2	2	-2	-2	-1	-8
F	-3	-4	-3	-6	-4	-5	-5	-5	-2	1	2	-5	0	9	-5	-3	-3	0	7	-1	-4	-5	-2	-8
P	1	0	0	-1	-3	0	-1	0	0	-2	-3	-1	-2	-5	6	1	0	-6	-5	-1	-1	0	-1	-8
S	1	0	1	0	0	-1	0	1	-1	-1	-3	0	-2	-3	1	2	1	-2	-3	-1	0	0	0	-8
T	1	-1	0	0	-2	-1	0	0	-1	0	-2	0	-1	-3	0	1	3	-5	-3	0	0	-1	0	-8
W	-6	2	-4	-7	-8	-5	-7	-7	-3	-5	-2	-3	-4	0	-6	-2	-5	17	0	-6	-5	-6	-4	-8
Y	-3	-4	-2	-4	0	-4	-4	-5	0	-1	-1	-4	-2	7	-5	-3	-3	0	10	-2	-3	-4	-2	-8
V	0	-2	-2	-2	-2	-2	-2	-1	-2	4	2	-2	2	-1	-1	-1	0	-6	-2	4	-2	-2	-1	-8
B	0	-1	2	3	-4	1	3	0	1	-2	-3	1	-2	-4	-1	0	0	-5	-3	-2	3	2	-1	-8
Z	0	0	1	3	-5	3	3	0	2	-2	-3	0	-2	-5	0	0	-1	-6	-4	-2	2	3	-1	-8
X	0	-1	0	-1	-3	-1	-1	-1	-1	-1	-1	-1	-1	-2	-1	0	0	-4	-2	-1	-1	-1	-1	-8
*	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	-8	1

Figure 3.11 – Matrice PAM 250 de M. Dayhoff.

III. Matrice de substitution	**Exemple et matrice PAM0**

- Ex. : ici on peut voir avec la **matrice de substitution** si le peptide 1 est plus proche du peptide 2 ou 3
  - Le principe est de donner un score à chaque alignement/colonne
  - Par exemple A sur le peptide 1 remplacé par L sur le peptide 2 a un score de -2
  - W sur le peptide 3 remplacé par A sur le peptide 1 a un score de -6
  - On fait de même pour toutes les structures de l'alignement
  - Au final on a un score global avec la somme de tous ces scores
- Conclusion : L'alignement entre le peptide 1 et 2 est largement mieux par rapport à l'alignement entre le peptide 1 et 3 (score 27 vs -32)
  - Les peptides 1 et 2 sont plus proches d'un point de vue évolutif
- Une autre matrice de substitution est la **matrice PAM0**
  - Consiste à ne considérer que les identités dans les comparaisons
  - On donne le score de 1 lorsque les deux résidus sont égaux
    - Sinon on donne la valeur 0

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V	B	Z	X
A	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
R	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
N	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1
D	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1
C	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
Q	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1
E	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1
G	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
H	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	1
I	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	1
L	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1
K	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	1
M	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	1
F	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	1
P	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	1
S	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	1
T	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	1
W	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	1
Y	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1
V	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	1
B	0	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1
Z	0	0	0	0	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1
X	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1

Figure 3.12 – Matrice unitaire pour les protéines (PAM0).

III. Matrice de substitution

Matrice BLOSUM 62

- **Matrice BLOSUM 62** (BLOck of amino acids SUbstitution Matrix) :
  - Une des plus utilisées dans les programmes de comparaison de séquences
  - Ici on regarde les scores dans la table de substitution entre les différents acides aminés

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V	B	Z	X	*
A	4	-1	-2	-2	0	-1	-1	0	-2	-1	-1	-1	-1	-2	-1	1	0	-3	-2	0	-2	-1	0	-4
R	-1	5	0	-2	-3	1	0	-2	0	-3	-2	2	-1	-3	-2	-1	-1	-3	-2	-3	-1	0	-1	-4
N	-2	0	6	1	-3	0	0	0	1	-3	-3	0	-2	-3	-2	1	0	-4	-2	-3	3	0	-1	-4
D	-2	-2	1	6	-3	0	2	-1	-1	-3	-4	-1	-3	-3	-1	0	-1	-4	-3	-3	4	1	-1	-4
C	0	-3	-3	-3	9	-3	-4	-3	-3	-1	-1	-3	-1	-2	-3	-1	-1	-2	-2	-1	-3	-3	-2	-4
Q	-1	1	0	0	-3	5	2	-2	0	-3	-2	1	0	-3	-1	0	-1	-2	-1	-2	0	3	-1	-4
E	-1	0	0	2	-4	2	5	-2	0	-3	-3	1	-2	-3	-1	0	-1	-3	-2	-2	1	4	-1	-4
G	0	-2	0	-1	-3	-2	-2	6	-2	-4	-4	-2	-3	-3	-2	0	-2	-2	-3	-3	-1	-2	-1	-4
H	-2	0	1	-1	-3	0	0	-2	8	-3	-3	-1	-2	-1	-2	-1	-2	-2	2	-3	0	0	-1	-4
I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4	2	-3	1	0	-3	-2	-1	-3	-1	3	-3	-3	-1	-4
L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4	-2	2	0	-3	-2	-1	-2	-1	1	-4	-3	-1	-4
K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5	-1	-3	-1	0	-1	-3	-2	-2	0	1	-1	-4
M	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5	0	-2	-1	-1	-1	-1	1	-3	-1	-1	-4
F	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6	-4	-2	-2	1	3	-1	-3	-3	-1	-4
P	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7	-1	-1	-4	-3	-2	-2	-1	-2	-4
S	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4	1	-3	-2	-2	0	0	0	-4
T	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5	-2	-2	0	-1	-1	0	-4
W	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11	2	-3	-4	-3	-2	-4
Y	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7	-1	-3	-2	-1	-4
V	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4	-3	-2	-1	-4
B	-2	-1	3	4	-3	0	1	-1	0	-3	-4	0	-3	-3	-2	0	-1	-4	-3	-3	4	1	-1	-4
Z	-1	0	0	1	-3	3	4	-2	0	-3	-3	1	-1	-3	-1	0	-1	-3	-2	-2	1	4	-1	-4
X	0	-1	-1	-1	-2	-1	-1	-1	-1	-1	-1	-1	-1	-1	-2	0	0	-2	-1	-1	-1	-1	-1	-4
*	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	-4	1

Figure 3.14 – Matrice BLOSUM 62.

IV. Programmation dynamique

Description

- L'algorithme doit trouver, parmi toutes les manières possibles d'aligner les séquences, celle qui a le score le plus élevé
- **Pour 2 séquences de longueur totale n, il existe 2^n façons de les aligner**
  - **Temps d'exécution considérables**
- Développement d'algorithmes capables de trouver la meilleure solution sans avoir à évaluer explicitement toutes les solutions possibles
- **Programmation dynamique** :
  - Résoudre un problème en le décomposant en sous-problèmes
  - Puis à résoudre les sous-problèmes, des plus petits aux plus grands en stockant les résultats intermédiaires

V. Recherche globale ou locale	**Explication**
	• Traitement informatique le plus commun des biologistes : ○ Comparaison d'une séquence avec une banque de séquences ○ Intérêt sur la longueur de la protéine et les domaines de la protéine ▪ **Recherche globale** : pour donner un score sur toute la longueur de l'alignement ▪ **Recherches locales** : aligner seulement une partie de la protéine (un domaine spécifique) ○ Ex. : Pour voir s'il y a des domaines très similaires entre des protéines très différentes 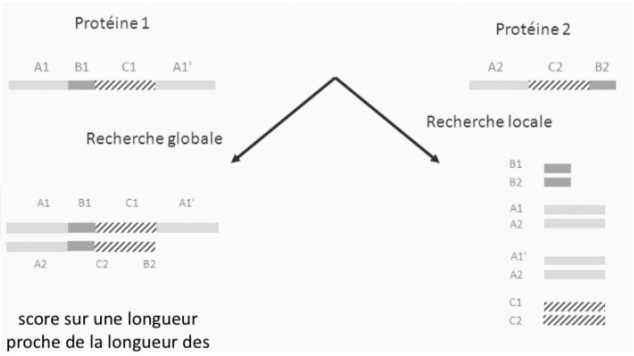

VI. BLAST (Basic Local Alignment Search Tool)	**Généralités**

Définition	• **Outil accessible en ligne**
	• Utilisé en bio-informatique pour **rechercher des régions similaires** entre deux ou plusieurs séquences nucléotidiques ou protéiques
	  ○ Inclus dans les **principales bases de données** de séquences du monde
	• Sélectionne a priori un **sous-ensemble de séquences** de la base de données qui répondent à certains critères
	  ○ Il calcule seulement pour celles-ci un alignement local avec la séquence à comparer
	• Fournit un score pour chaque alignement
	  ○ Utilise ce score pour donner une évaluation statistique de la pertinence de cet alignement (probabilité qu'il soit dû au hasard)

Exemple de l'interface BLAST	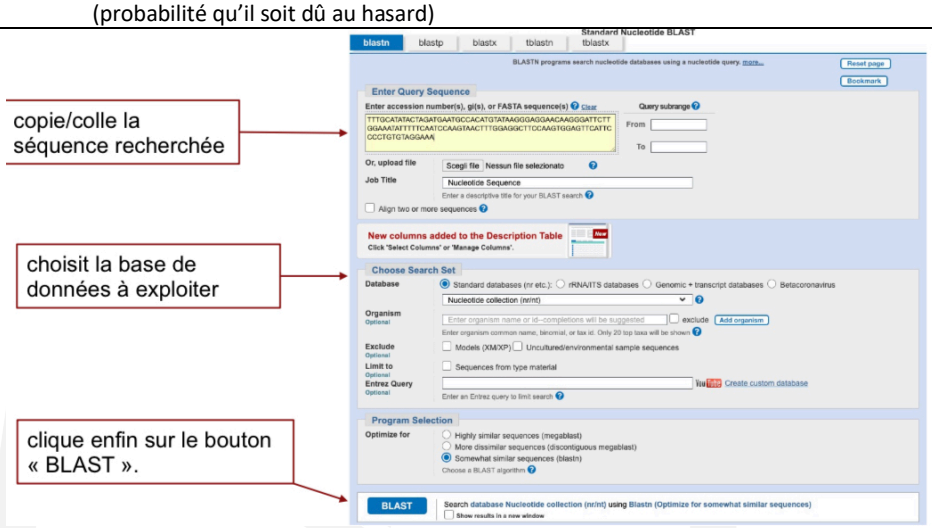 • On a la **séquence d'intérêt** que l'on va essayer de comparer (copie/colle) • On peut aussi rentrer la séquence en **format FASTA** • Ensuite on indique la **base de données** que l'on veut regarder • À la fin on peut par exemple cocher le fait que l'on veut un score pour toutes les **séquences qui sont similaires** à la séquence d'intérêt

VI. BLAST (Basic Local Alignment Search Tool)	**Généralités**

Exemple de résultat à la recherche	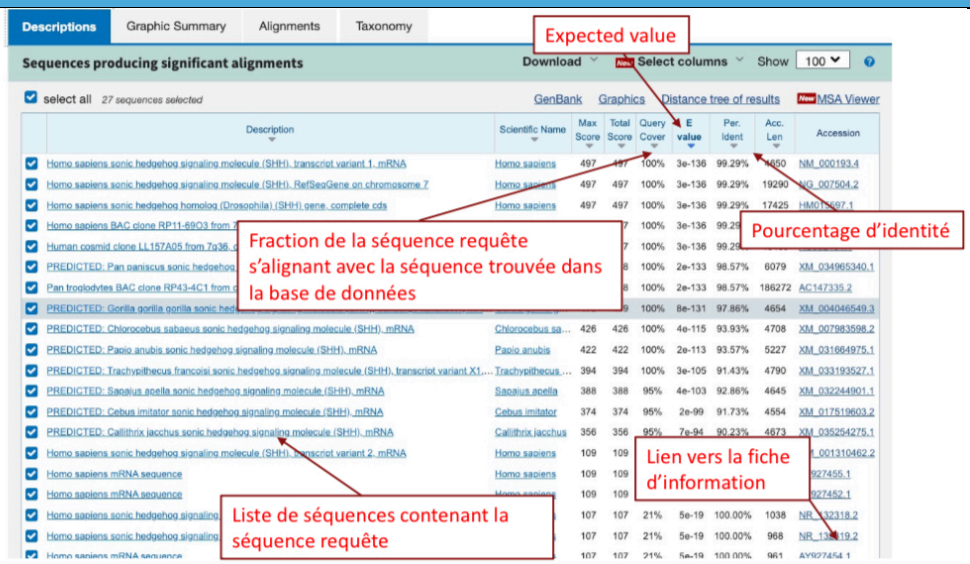
	
	• On obtient toutes les séquences que l'on trouve dans la base de données de séquences qui sont **proches de notre séquence d'intérêt**
	  ○ Il y a des informations sur le **score d'alignement**
	  ○ Sur la **fraction de la séquence requête** qui s'aligne avec la séquence trouvée dans la base de données
	  ○ Il y a aussi un **pourcentage d'identité** entre les 2 séquences
	  ○ Information de **type statistique** avec « E value » : est-ce que dans notre séquence trouvée l'alignement est vrai ou est alors dû au hasard
	  ▪ Le E value doit toujours être **inférieur à 1**

VI. BLAST (Basic Local Alignment Search Tool)	**Généralités**

Pour aller plus loin	• Onglet **résultats** : fabrication d'un graphique avec tous les alignements produits
	  ○ Code couleur selon les scores :
	  ▪ Rouge : code couleur maximal
	  ▪ Noir : code couleur faible
	• **Tailles pour chaque alignement** :
	  ○ On voit les détails de l'alignement
	  ○ On voit un alignement parfait presque partout
	  ▪ Sauf lorsqu'on a une absence d'identité (substitution)
	 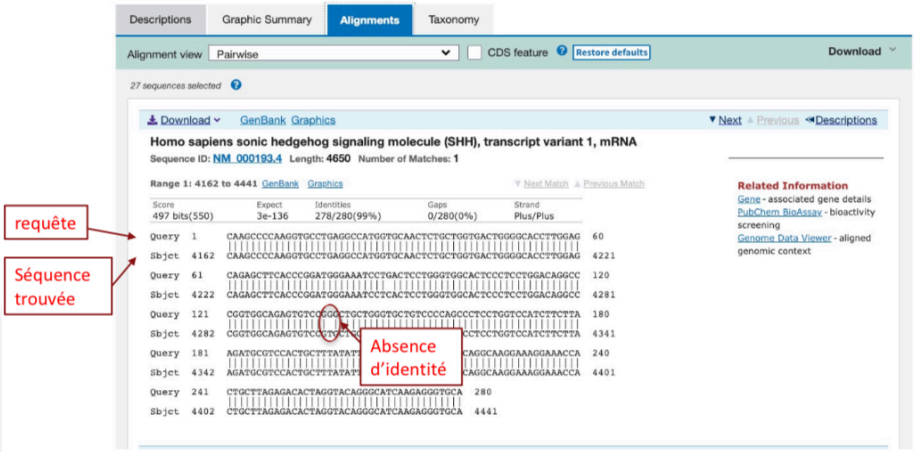
	
	• Il y a toujours **l'information sur les scores** qui est calculée avec les matrices de substitution
	  ○ Pour les protéines on peut utiliser les matrices de substitution Blossom 62
	  ○ On voit aussi l'identité, et le nombre de gap